

- scRareRefine P0 分析报告：Immune DC / ASDC rare known annotation
  - 1. 背景与目标
  - 2. 数据集当前情况
  - 3. 实验设置
  - 4. 不做后处理时：scANVI baseline
  - 5. 基于 scANVI 做了什么改动
  - 6. 加 prototype 后处理后的效果
    - 6.1 Direct relabel simulation
    - 6.2 Review-list 效果
  - 7. 为什么 prototype 有效
  - 8. 运行时间与内存
  - 9. 当前结论
  - 10. M4 marker verifier 初步结果
    - 10.1 Marker threshold curve
    - 10.2 Held-out validation-tuned threshold
  - 11. 置信度感知概率融合（Confidence-aware Probability Fusion）
    - 11.1 动机
    - 11.2 方法：概率融合
    - 11.3 诊断：为什么纯 margin-based  $\alpha$  不够
    - 11.4 Disagreement-aware weighting
    - 11.5 结果
    - 11.6 结论
    - 11.7 与之前 M2 + M4 方案的对比
  - 12. 输出文件

# scRareRefine P0 分析报告：Immune DC / ASDC rare known annotation

---

## 1. 背景与目标

---

本阶段围绕 `human_immune_health_atlas_dc.h5ad` 做 P0 验证，目标不是发现未知细胞，而是验证：

已知稀有类 ASDC 在训练集中只保留少量标注时，scANVI 是否会把它吞并到邻近大类；以及 scANVI 输出的 latent embedding / uncertainty 是否足以支持 rare-

当前实验对应研究方案中的两个模块：

- **M2 Prototype-distance Rescue**：在 scANVI latent space 中，用训练集中已标注细胞建立各类 prototype，检查被错分细胞是否更接近 ASDC prototype。
- **M5 Uncertainty Gate / Selective Refinement**：用 entropy / margin 等不确定性指标给高风险细胞排序。

当前还没有实现或验证：

- M1 balanced latent classifier
- M3 local-density / neighbor-purity
- M4 marker-consistency verifier
- M6 latent oversampling

因此，本报告中的“加模块后”主要指 **scANVI** 后处理阶段的 **prototype rule / review ranking**，不是重新训练了一个新 backbone。

## 2. 数据集当前情况

---


数据集：

data/human\_immune\_health/human\_immune\_health\_atlas\_dc.h5ad

配置：

- 标签列：AIFI\_L3
- batch 列：batch\_id
- 训练矩阵：raw.X
- 总细胞数：23,287
- 细胞类型数：6
- batch 数：36

按 <5% 定义，ASDC 和 cDC1 是 rare candidates。本阶段主攻 ASDC。



| Cell type     | Count | Fraction |
|---------------|-------|----------|
| pDC           | 7,587 | 32.58%   |
| HLA-DRhi cDC2 | 7,353 | 31.58%   |
| CD14+ cDC2    | 5,646 | 24.25%   |
| ISG+ cDC2     | 1,236 | 5.31%    |
| cDC1          | 943   | 4.05%    |
| ASDC          | 522   | 2.24%    |

### 3. 实验设置

对 ASDC 做 controlled downsampling:

| Setting       | ASDC labeled training cells | Seeds      |
|---------------|-----------------------------|------------|
| extreme rare  | 20                          | 42, 43, 44 |
| rare          | 50                          | 42, 43, 44 |
| moderate rare | 100                         | 42, 43, 44 |
| full label    | all                         | 42, 43, 44 |


scANVI 设置：

- HVG: 3,000 genes
- latent dim: 30
- scVI epochs: 200
- scANVI epochs: 100
- unlabeled category: **Unknown**

注意：未标注 ASDC 的真实标签只用于最终评估，不进入 `scanvi_label` 训练列。

## 4. 不做后处理时：scANVI baseline

scANVI 在整体指标上表现很高，但 ASDC recall 会随训练标注数量明显变化。**20** 个 ASDC label 时 seed 方差较大，说明极少样本下 baseline 不稳定。



| ASDC train size | ASDC recall mean | ASDC F1 mean | Macro-F1 mean |
|-----------------|------------------|--------------|---------------|
| 20              | 0.532            | 0.642        | 0.929         |
| 50              | 0.879            | 0.935        | 0.977         |
| 100             | 0.894            | 0.943        | 0.980         |
| all             | 0.991            | 0.995        | 0.986         |

最典型的 failure 来自 `seed=42, ASDC_train_size=20`:

| Metric           | Value  |
|------------------|--------|
| overall accuracy | 0.9699 |
| macro-F1         | 0.8586 |
| ASDC precision   | 1.0000 |
| ASDC recall      | 0.1360 |
| ASDC F1          | 0.2395 |

该 run 中 ASDC 错分去向:

| Misclassified as | Count |
|------------------|-------|
| HLA-DRhi cDC2    | 270   |
| pDC              | 176   |
| ISG+ cDC2        | 4     |
| cDC1             | 1     |

这说明 scANVI 的问题不是随机噪声，而是符合研究假设的 **rare-to-neighbor-major absorption**: ASDC 被邻近 DC 大类吞并。

## 5. 基于 scANVI 做了什么改动

当前没有改 scANVI 内部 loss，也没有替换 backbone。我们做的是 **post-hoc rare-aware refinement / review**:

1. 训练标准 scVI/scANVI。
2. 提取每个细胞的：
  - latent embedding
  - predicted label
  - prediction probability
  - entropy
  - margin
3. 用训练集中有标签细胞，在 latent space 中建立每个 cell type 的 prototype。
4. 对每个细胞计算：

- 到 ASDC prototype 的距离
- 到预测类 prototype 的距离
- ASDC prototype rank
- $d_{\text{pred}} - d_{\text{ASDC}}$

5. 用 prototype score 生成 review list；并模拟一个简单 rescue rule：

```
pred != ASDC
and prototype_rank_ASDC <= 2
and margin <= 25% quantile
=> relabel as ASDC
```


这个 rule 当前只是验证 M2 是否有效，不是最终模型。最终版本仍应加入 M4 marker verifier 来控制 false positive。

## 6. 加 prototype 后处理后的效果

### 6.1 Direct relabel simulation

prototype rule 在极少 label 场景下能明显提升 ASDC recall / F1；但当 ASDC label 已经充足时，baseline 本身已经很强，直接 relabel 会引入 false positive。

Prototype relabel simulation vs scANVI baseline



| ASDC<br>train<br>size | Method                    | Accuracy<br>mean | Macro-<br>F1 mean | ASDC<br>precision<br>mean | ASDC<br>recall<br>mean | ASDC<br>F1<br>mean |
|-----------------------|---------------------------|------------------|-------------------|---------------------------|------------------------|--------------------|
| 20                    | scANVI<br>baseline        | 0.9789           | 0.9285            | 1.0000                    | 0.5319                 | 0.6424             |
| 20                    | prototype<br>rule relabel | 0.9846           | 0.9717            | 0.8826                    | 0.9049                 | 0.8930             |
| 50                    | scANVI<br>baseline        | 0.9832           | 0.9767            | 0.9986                    | 0.8793                 | 0.9349             |
| 50                    | prototype<br>rule relabel | 0.9799           | 0.9673            | 0.8144                    | 0.9770                 | 0.8842             |
| 100                   | scANVI<br>baseline        | 0.9866           | 0.9803            | 0.9986                    | 0.8940                 | 0.9434             |
| 100                   | prototype<br>rule relabel | 0.9843           | 0.9729            | 0.8369                    | 0.9828                 | 0.9032             |
| all                   | scANVI<br>baseline        | 0.9848           | 0.9859            | 0.9981                    | 0.9911                 | 0.9945             |
| all                   | prototype<br>rule relabel | 0.9776           | 0.9613            | 0.7535                    | 0.9987                 | 0.8587             |


结论：

- 在 20 个 ASDC label 时，prototype relabel 从 ASDC F1=0.642 提升到 0.893。
- 在 50/100/all 时，prototype rule 虽然继续提高 recall，但 precision 明显下降，F1 反而不一定提升。
- 因此 prototype 更适合作为 **selective rescue / review signal**，而不是无条件全自动改标签。

## 6.2 Review-list 效果

作为 review ranking，prototype 明显强于 entropy。

Review-list recall: prototype vs uncertainty



Top-5% review recall:

| ASDC train size | Entropy mean | Prototype mean |
|-----------------|--------------|----------------|
| 20              | 0.421        | 0.970          |
| 50              | 0.430        | 0.932          |
| 100             | 0.492        | 0.924          |
| all             | 0.263        | 0.606          |

解释:

- 20/50/100 三档中, prototype top-5% 能覆盖约 92% – 97% 的 ASDC errors。
- entropy top-5% 只能覆盖约 42% – 49%。
- all 档中 ASDC error 数量很少, review recall 分母小, 波动大, 参考意义较弱。

## 7. 为什么 prototype 有效

当前结果说明 scANVI 的错误主要发生在 分类头/决策边界层面, 而不是 latent space 完全不可分。

具体原因:

1. **ASDC 在 latent space 中仍保留几何邻近性**很多被 scANVI 预测成 HLA-DRhi cDC2 或 pDC 的 ASDC, 在 latent geometry 上更接近 ASDC prototype。
2. **scANVI 对 rare class 偏保守**在 seed=42, train\_size=20 中, scANVI 只预测了 71 个 ASDC, precision 为 1.0, 但 recall 只有 0.136。说明模型宁可少报 ASDC, 也不愿把邻近大类改成 rare class。
3. **prototype score 提供了与 softmax 不同的信息**entropy/margin 只看分类概率; prototype distance 直接看 latent 空间的几何结构。结果中 prototype top-5% review


recall 远高于 entropy，说明几何证据更适合 ASDC rescue。

4. **rare failure** 主要集中在相近 **DC** 亚型之间 错误主要流向 **HLA-DRhi cDC2** 和 **pDC**，这正是 prototype/local geometry 方法最容易发挥作用的场景。

## 8. 运行时间与内存

新加了资源记录：

- wall\_time\_seconds
- peak\_rss\_mb



| ASDC train size | Runtime mean | Peak RSS mean |
|-----------------|--------------|---------------|
| 20              | 759.0 s      | 1956 MB       |
| 50              | 544.0 s      | 1666 MB       |
| 100             | 543.1 s      | 1544 MB       |
| all             | 540.6 s      | 1555 MB       |

seed=42, train\_size=20 是加资源监控前跑的，因此该 run 的时间/内存为空；20 档资源均值只来自 seed=43/44。

## 9. 当前结论

当前阶段可以得出几个比较稳的结论：

1. **scANVI baseline** 已经很强，但 **rare class** 仍有明显风险ASDC 在少标签场景下存在明显 recall failure，尤其是 20 个标注时。
2. **M2 Prototype-distance Rescue** 是有效信号作为 review ranking，prototype 在 20/50/100 三档中稳定优于 entropy。
3. **不建议直接无条件 relabel**在 ASDC label 很少时，prototype relabel 明显提升 F1；但当 baseline 已经较强时，它会带来 false positive，降低 precision。
4. **下一步应该加入 M4 marker verifier 或更严格 gate** 当前 prototype rule 的主要风险是过度 rescue。合理路径是：

```
prototype high-risk candidate  
+ marker consistency support  
=> auto rescue
```

```
prototype support but marker weak  
=> review list only
```

## 10. M4 marker verifier 初步结果

在后续推进中，我们加入了第一版 **train-only marker verifier**：

```
prototype rank1 candidate  
+ ASDC marker score > original predicted-class marker score  
=> marker-verified rescue
```

marker signature 只从每个 run 的训练标注细胞中计算，不使用测试标签，因此避免了 test leakage。该版本不接外部 marker 数据库，目的是先验证 marker consistency 能否降低 prototype rescue 的 false positive。

对比结果如下：

| ASDC<br>train<br>size | Method                        | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|-------------------------------|-------------------|----------------|------------|--------------|-------------------------|
| 20                    | scANVI<br>baseline            | 1.000             | 0.532          | 0.642      | 0.929        | 0.0000                  |
| 20                    | prototype<br>rank1 gate       | 0.915             | 0.945          | 0.930      | 0.978        | 0.0020                  |
| 20                    | rank1 + train-<br>only marker | 0.989             | 0.673          | 0.784      | 0.953        | 0.0001                  |
| 50                    | scANVI<br>baseline            | 0.999             | 0.879          | 0.935      | 0.977        | 0.0000                  |
| 50                    | prototype<br>rank1 gate       | 0.928             | 0.956          | 0.942      | 0.978        | 0.0017                  |
| 50                    | rank1 + train-<br>only marker | 0.988             | 0.904          | 0.944      | 0.978        | 0.0002                  |
| 100                   | scANVI<br>baseline            | 0.999             | 0.894          | 0.943      | 0.980        | 0.0000                  |
| 100                   | prototype<br>rank1 gate       | 0.928             | 0.961          | 0.944      | 0.980        | 0.0017                  |
| 100                   | rank1 + train-<br>only marker | 0.992             | 0.914          | 0.951      | 0.982        | 0.0001                  |
| all                   | scANVI<br>baseline            | 0.998             | 0.991          | 0.995      | 0.986        | 0.0000                  |
| all                   | prototype<br>rank1 gate       | 0.932             | 0.995          | 0.962      | 0.980        | 0.0017                  |
| all                   | rank1 + train-<br>only marker | 0.994             | 0.992          | 0.993      | 0.986        | 0.0001                  |

 M4 marker verifier comparison

结论：

1. **prototype rank1 gate** 是强 rescue 策略：recall 高，但 precision 会下降。

2. **rank1 + train-only marker** 是保守策略：显著降低 false rescue，并恢复 precision，但在 20-label 场景中会牺牲一部分 recall。
3. 对 **50/100** 两档，marker verifier 比 baseline 略有提升，同时 false rescue rate 保持在约 **0.01% - 0.02%**。
4. 第一版 train-only marker 太保守，适合作为 auto-rescue gate；prototype rank1 更适合作为 review-list candidate generator。

## 10.1 Marker threshold curve

为了避免 **marker\_margin > 0** 过于保守，我们进一步评估了 marker margin 阈值曲线。每个 run 在候选集合内扫描多个 marker threshold，并在 false rescue rate 不超过 **0.1%** 的约束下选择 ASDC F1 最高的阈值。

 Tuned marker threshold comparison

| ASDC<br>train<br>size | Method                    | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|---------------------------|-------------------|----------------|------------|--------------|-------------------------|
| 20                    | scANVI<br>baseline        | 1.000             | 0.532          | 0.642      | 0.929        | 0.0000                  |
| 20                    | prototype<br>rank1 gate   | 0.915             | 0.945          | 0.930      | 0.978        | 0.0020                  |
| 20                    | marker<br>margin > 0      | 0.989             | 0.673          | 0.784      | 0.953        | 0.0001                  |
| 20                    | tuned marker<br>threshold | 0.954             | 0.796          | 0.858      | 0.966        | 0.0008                  |
| 50                    | scANVI<br>baseline        | 0.999             | 0.879          | 0.935      | 0.977        | 0.0000                  |
| 50                    | prototype<br>rank1 gate   | 0.928             | 0.956          | 0.942      | 0.978        | 0.0017                  |
| 50                    | marker<br>margin > 0      | 0.988             | 0.904          | 0.944      | 0.978        | 0.0002                  |
| 50                    | tuned marker<br>threshold | 0.981             | 0.930          | 0.954      | 0.980        | 0.0004                  |

| ASDC<br>train<br>size | Method                    | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|---------------------------|-------------------|----------------|------------|--------------|-------------------------|
| 100                   | scANVI<br>baseline        | 0.999             | 0.894          | 0.943      | 0.980        | 0.0000                  |
| 100                   | prototype<br>rank1 gate   | 0.928             | 0.961          | 0.944      | 0.980        | 0.0017                  |
| 100                   | marker<br>margin > 0      | 0.992             | 0.914          | 0.951      | 0.982        | 0.0001                  |
| 100                   | tuned marker<br>threshold | 0.973             | 0.949          | 0.961      | 0.983        | 0.0006                  |

调参后可以看到：

- 20 档仍然是 prototype rank1 F1 最高，但 tuned marker threshold 在 precision 和 false rescue 之间更稳。
- 50/100 档 tuned marker threshold 的 F1 高于 baseline、rank1 gate 和 marker\_margin > 0。
- tuned marker threshold 保留了 marker verifier 的核心价值：false rescue rate 低于 prototype rank1，同时比固定 marker\_margin > 0 救回更多 ASDC。

## 10.2 Held-out validation-tuned threshold

上一节的 tuned marker threshold 是在完整评估集上扫描阈值，用来判断 marker margin 是否有信号；它适合做探索分析，但不应作为最终无泄漏性能估计。为此，我们进一步把每个 run 的细胞按真实类别分层切成 validation/test：只在 validation cells 上选择 marker threshold，再在 held-out test cells 上评估。

默认比较 alpha=0.1% false-rescue 约束时，结果如下：

| ASDC<br>train<br>size | Method                     | alpha | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|----------------------------|-------|-------------------|----------------|------------|--------------|-------------------------|
| 20                    | scANVI<br>baseline<br>test |       | 1.000             | 0.519          | 0.629      | 0.926        | 0.0000                  |

| ASDC<br>train<br>size | Method                              | alpha | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|-------------------------------------|-------|-------------------|----------------|------------|--------------|-------------------------|
| 20                    | prototype<br>rank1 gate<br>test     |       | 0.912             | 0.948          | 0.929      | 0.978        | 0.0021                  |
| 20                    | validation-<br>tuned<br>marker test | 0.001 | 0.951             | 0.784          | 0.850      | 0.964        | 0.0009                  |
| 50                    | scANVI<br>baseline<br>test          |       | 0.999             | 0.879          | 0.935      | 0.977        | 0.0000                  |
| 50                    | prototype<br>rank1 gate<br>test     |       | 0.922             | 0.959          | 0.940      | 0.978        | 0.0018                  |
| 50                    | validation-<br>tuned<br>marker test | 0.001 | 0.974             | 0.928          | 0.950      | 0.980        | 0.0006                  |
| 100                   | scANVI<br>baseline<br>test          |       | 0.999             | 0.891          | 0.942      | 0.980        | 0.0000                  |
| 100                   | prototype<br>rank1 gate<br>test     |       | 0.923             | 0.963          | 0.943      | 0.980        | 0.0018                  |
| 100                   | validation-<br>tuned<br>marker test | 0.001 | 0.970             | 0.953          | 0.961      | 0.983        | 0.0006                  |
| all                   | scANVI<br>baseline<br>test          |       | 0.997             | 0.990          | 0.994      | 0.987        | 0.0000                  |
| all                   | prototype<br>rank1 gate<br>test     |       | 0.924             | 0.994          | 0.957      | 0.980        | 0.0018                  |

| ASDC<br>train<br>size | Method      | alpha | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1 | Macro-<br>F1 | False<br>rescue<br>rate |
|-----------------------|-------------|-------|-------------------|----------------|------------|--------------|-------------------------|
|                       | validation- |       |                   |                |            |              |                         |
| all                   | tuned       | 0.001 | 0.989             | 0.991          | 0.990      | 0.986        | 0.0002                  |
|                       | marker test |       |                   |                |            |              |                         |

 Validation-tuned marker comparison

该验证说明：

- held-out 评估后，**50/100** 档的结论仍然成立：validation-tuned marker verifier 的 ASDC F1 仍高于 baseline 和 prototype rank1，同时 false rescue 明显低于 rank1。
- 20** 档在 **alpha=0.1%** 时仍偏保守，F1 低于 prototype rank1；但如果放宽到 **alpha=0.2%**，held-out ASDC F1 达到约 **0.936**，已经略高于 rank1 的 **0.929**，false rescue rate 约 **0.0011**，说明 20-label 场景更依赖 false-positive 容忍度。
- all** 档 baseline 仍然最好，后处理只应作为 rare-label 场景的 selective rescue，而不是 full-label 场景默认步骤。

因此，当前最稳的主方法表述应更新为：**prototype rank1 生成候选；marker threshold 在 validation set 中按 false-rescue 约束选择；最终只报告 held-out test performance。**

## 11. 置信度感知概率融合（Confidence-aware Probability Fusion）

### 11.1 动机

前述 M2 prototype gate + M4 marker verifier 的组合虽然可行，但存在稳定性问题：

- 二元 rescue 决策（rescue / 非 rescue）过于粗糙
- prototype rank1 gate 在 baseline 已经很强时（**50/100/all**）会引入 false positive，反而拉低 F1
- marker verifier 作为 veto 又过于保守，尤其在 **20** 档丢失大量 recall

核心问题是：系统不知道什么时候该出手、什么时候该闭嘴。

## 11.2 方法：概率融合

不再做二元 rescue 决策，而是将 scANVI 的 softmax 概率与 prototype 距离导出的概率进行连续融合：

$$p_{\text{fused}}(y|x) = \alpha(x) \cdot p_{\text{scanvi}}(y|x) + (1 - \alpha(x)) \cdot p_{\text{proto}}(y|x)$$

其中：

- $p_{\text{proto}}(y=c|x) = \exp(-d(z_x, \mu_c)/\tau) / \sum_k \exp(-d(z_x, \mu_k)/\tau)$ ，类似 prototypical networks
- $\alpha(x)$  是 per-cell 的融合权重，由 scANVI 自身置信度决定
- $\tau$  是 prototype softmax 的温度参数

## 11.3 诊断：为什么纯 margin-based $\alpha$ 不够

对  $\text{seed}=42$ ， $\text{ASDC\_train\_size}=20$  (baseline F1=0.218) 进行诊断发现：

| ASDC errors (451 个) | 数量  | 占比    |
|---------------------|-----|-------|
| margin > 0.9        | 351 | 77.8% |
| margin > 0.5        | 400 | 88.7% |
| margin < 0.1        | 17  | 3.8%  |

**scANVI 不是"不确定地错了"，而是"非常自信地错了"。**如果  $\alpha$  仅由 margin 驱动，即使  $\alpha_{\text{min}}=0$ ，88% 的错误细胞的  $\alpha$  仍在 0.9+，scANVI 概率仍然主导，prototype 信号无法介入。

## 11.4 Disagreement-aware weighting

引入 disagreement discount factor  $\beta$ ：

$$\alpha_{\text{base}}(x) = \alpha_{\text{min}} + (1 - \alpha_{\text{min}}) \cdot \text{margin}(x)$$

如果  $\text{argmax } p_{\text{scanvi}}(x) \neq \text{argmax } p_{\text{proto}}(x)$ ：  
 $\alpha(x) = \alpha_{\text{base}}(x) \times \beta$

否则:

$$\alpha(x) = \alpha_{\text{base}}(x)$$


- 当 prototype 与 scANVI 预测一致时,  $\alpha$  保持高值 (不干预)
- 当两者分歧时,  $\alpha$  被  $\beta$  打折, prototype 信号获得话语权
- $\beta=1.0$  退化为纯 margin-based 融合;  $\beta \rightarrow 0$  时 disagree 的细胞完全信任 prototype

超参 ( $\tau$ ,  $\alpha_{\text{min}}$ ,  $\beta$ ) 在 validation set 上 grid search, 选择满足 accuracy drop  $\leq 1\%$  且 false rescue rate  $\leq 1\%$  约束下 rare\_f1 最高的组合。

## 11.5 结果

Held-out test 评估 (3 seeds 均值):

| ASDC<br>train<br>size | Method             | ASDC<br>precision | ASDC<br>recall | ASDC<br>F1   | Macro-<br>F1 | Accuracy     | False<br>rescue<br>rate |
|-----------------------|--------------------|-------------------|----------------|--------------|--------------|--------------|-------------------------|
| 20                    | scANVI<br>baseline | 1.000             | 0.519          | 0.629        | 0.926        | 0.978        | 0.0000                  |
| 20                    | <b>fusion</b>      | <b>0.977</b>      | <b>0.899</b>   | <b>0.936</b> | <b>0.977</b> | <b>0.984</b> | 0.0005                  |
| 50                    | scANVI<br>baseline | 0.999             | 0.879          | 0.935        | 0.977        | 0.983        | 0.0000                  |
| 50                    | <b>fusion</b>      | <b>0.976</b>      | <b>0.932</b>   | <b>0.954</b> | <b>0.978</b> | 0.981        | 0.0005                  |
| 100                   | scANVI<br>baseline | 0.999             | 0.891          | 0.942        | 0.980        | 0.986        | 0.0000                  |
| 100                   | <b>fusion</b>      | <b>0.985</b>      | <b>0.935</b>   | <b>0.959</b> | <b>0.980</b> | 0.983        | 0.0003                  |
| all                   | scANVI<br>baseline | 0.997             | 0.990          | 0.994        | 0.987        | 0.985        | 0.0000                  |
| all                   | fusion             | 0.991             | 0.994          | 0.992        | 0.986        | 0.984        | 0.0001                  |



Validation-tuned 选出的超参：

| Seed | ASDC train size | $\tau$ | $\alpha_{\min}$ | $\beta$ |
|------|-----------------|--------|-----------------|---------|
| 42   | 20              | 0.50   | 0.0             | 0.3     |
| 42   | 50              | 2.00   | 0.0             | 0.1     |
| 42   | 100             | 0.10   | 0.3             | 0.5     |
| 42   | all             | 0.10   | 0.0             | 1.0     |
| 43   | 20              | 0.10   | 0.0             | 0.5     |
| 43   | 50              | 0.25   | 0.0             | 0.3     |
| 43   | 100             | 0.25   | 0.7             | 0.3     |
| 43   | all             | 1.00   | 0.5             | 0.1     |
| 44   | 20              | 0.10   | 0.0             | 0.5     |
| 44   | 50              | 0.10   | 0.7             | 0.5     |
| 44   | 100             | 1.00   | 0.2             | 0.3     |
| 44   | all             | 0.25   | 0.5             | 0.5     |

## 11.6 结论

- 所有 **20/50/100** 档，fusion 的 **ASDC F1** 都稳定优于 **baseline**。20 档从 **0.629**  $\rightarrow$  **0.936** (+0.307)，50 档从 **0.935**  $\rightarrow$  **0.954** (+0.019)，100 档从 **0.942**  $\rightarrow$  **0.959** (+0.017)。
- all** 档融合自动退化 (F1 从 0.994  $\rightarrow$  0.992，差 0.002)，不会伤害 baseline 已经很强的场景。
- False rescue rate** 控制在 **0.05%** 以内，precision 从 ~1.0 下降到 ~0.977，属于可接受范围。

- 4.  $\beta$  是关键因子：20 档选出  $\beta=0.3\sim0.5$ ，说明在 rare label 极少时需要大幅降低 disagreement 区域的 scANVI 权重；all 档  $\beta$  趋向 1.0（不需要 disagreement discount），与预期一致。
- 5. 概率融合相比之前的二元 gate + marker 方案，最大优势是稳定性：不存在"某些设定下比 baseline 差"的问题。

## 11.7 与之前 M2 + M4 方案的对比

| Method                             | 20<br>F1     | 50<br>F1     | 100<br>F1    | all F1       | 始终 $\geq$<br>baseline? |
|------------------------------------|--------------|--------------|--------------|--------------|------------------------|
| scANVI baseline                    | 0.629        | 0.935        | 0.942        | 0.994        | ✓                      |
| prototype rank1 gate               | 0.929        | 0.940        | 0.943        | 0.957        | ✗ all 档差               |
| rank1 + marker (margin>0)          | 0.784        | 0.944        | 0.951        | 0.993        | ✗ 20 档差                |
| validation-tuned marker            | 0.850        | 0.950        | 0.961        | 0.990        | ✗ all 档差               |
| <b>fusion (disagreement-aware)</b> | <b>0.936</b> | <b>0.954</b> | <b>0.959</b> | <b>0.992</b> | <b>✓ 全部 ✓</b>          |

融合方法在所有设定下都能做到不低于 baseline，同时在 rare label 不足的场景下提供显著提升。

## 12. 输出文件

关键结果文件：

- outputs/immune\_dc/p0/tables/rare\_train\_size\_curve\_runs.csv
- outputs/immune\_dc/p0/tables/rare\_train\_size\_curve\_summary.csv
- outputs/immune\_dc/p0/tables/prototype\_review\_recall\_summary.csv
- outputs/immune\_dc/p0/tables/uncertainty\_review\_recall\_summary.csv
- outputs/immune\_dc/p0/tables/prototype\_relabel\_effect\_runs.csv
- outputs/immune\_dc/p0/tables/prototype\_relabel\_effect\_summary.csv

- `outputs/immune_dc/p0/stages/prototype_gate/gate_effect_summary.csv`
- `outputs/immune_dc/p0/stages/marker_verifier/baseline_vs_gate_vs_marker_summary.csv`
- `outputs/immune_dc/p0/stages/marker_verifier/baseline_vs_gate_vs_marker_threshold_summary.csv`
- `outputs/immune_dc/p0/stages/marker_verifier/marker_threshold_curve_runs.csv`
- `outputs/immune_dc/p0/stages/marker_verifier/recommended_marker_thresholds.csv`
- `outputs/immune_dc/p0/stages/marker_threshold_validation/validation_tuned_effect_runs.csv`
- `outputs/immune_dc/p0/stages/marker_threshold_validation/validation_tuned_effect_summary.csv`
- `outputs/immune_dc/p0/stages/marker_threshold_validation/validation_threshold_curve_runs.csv`
- `outputs/immune_dc/p0/stages/marker_threshold_validation/selected_validation_thresholds.csv`
- `outputs/immune_dc/p0/stages/fusion/fusion_effect_runs.csv`
- `outputs/immune_dc/p0/stages/fusion/fusion_effect_summary.csv`
- `outputs/immune_dc/p0/stages/fusion/fusion_grid_search.csv`
- `outputs/immune_dc/p0/stages/fusion/selected_fusion_params.csv`

#### 报告图表:

- `docs/reports/figures/immune_dc_cell_distribution.png`
- `docs/reports/figures/scanvi_baseline_train_size_curve.png`
- `docs/reports/figures/review_recall_prototype_vs_entropy.png`
- `docs/reports/figures/prototype_relabel_effect.png`
- `docs/reports/figures/runtime_memory_summary.png`
- `docs/reports/figures/fusion_vs_baseline.png`
- `outputs/immune_dc/p0/stages/marker_verifier/baseline_vs_gate_vs_marker.png`
- `outputs/immune_dc/p0/stages/marker_verifier/baseline_vs_gate_vs_tuned_marker.png`
- `outputs/immune_dc/p0/stages/marker_threshold_validation/validation_tuned_marker_comparison.png`

- [outputs/immune\\_dc/p0/stages/fusion/fusion\\_vs\\_baseline.png](#)